



Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas
Projeto Integrador III — Ciência de Dados

HÓRUS

Sistema Inteligente de Fiscalização de Dados Públicos

ENTREGA 1 — RELATÓRIO DE ESCOPO

Instituição	FAESA — Centro Universitário
Curso	Tecnologia em Análise e Desenvolvimento de Sistemas (TADS)
Disciplina	Projeto Integrador III — Ciência de Dados
Professor	Howard Cruz
Aluno	Derek Cobain
Data	27 de março de 2026

Resumo

O Hórus é um sistema web de fiscalização pública que cruza dados de bases governamentais abertas para identificar automaticamente possíveis irregularidades financeiras envolvendo agentes públicos, empresas e contratos. O sistema usa técnicas de ciência de dados — grafos de relacionamento, detecção de anomalias e processamento de linguagem natural — para conectar informações que estão espalhadas em dezenas de portais distintos e que raramente são analisadas em conjunto.

Este documento é a primeira entrega do Projeto Integrador III e cobre o escopo do sistema, a justificativa do problema, as bases de dados que serão utilizadas, os principais cruzamentos de dados, a arquitetura técnica proposta e o plano de trabalho para o semestre.

Palavras-chave: Ciência de Dados, Transparência Pública, Detecção de Anomalias, Grafos de Relacionamento, Fiscalização, Dados Abertos, FastAPI, PostgreSQL, Next.js.

Sumário

Resumo	3
1 Introdução e Justificativa	1
2 Problema Abordado	1
2.1 Por que isso importa	1
3 Objetivos	2
3.1 Objetivo Geral	2
3.2 Objetivos Específicos	2
4 Bases de Dados Utilizadas	2
4.1 Tier 1 — Núcleo Principal	2
4.2 Tier 2 — Enriquecimento	3
4.3 Nota Legal — LGPD e CPFs de Agentes Públicos	4
5 Cruzamentos e Detecção de Irregularidades	4
6 Solução Proposta — Arquitetura do Sistema	5
6.1 Stack Tecnológica	5
6.2 Arquitetura em Camadas	5
6.3 Por que PostgreSQL com Apache AGE e não Neo4j?	6
7 Sociedade Impactada	6
7.1 Métricas de Impacto	6
8 Plano de Trabalho e Cronograma	7
9 Considerações Finais	7
Referências	9

1. Introdução e Justificativa

O Brasil tem um dos sistemas de transparência pública mais robustos do mundo no papel. A Lei de Acesso à Informação, o Portal da Transparência, os dados do TSE, da Receita Federal e do TCU — tudo isso está disponível, aberto, gratuito. O problema é que está fragmentado em dezenas de portais sem integração entre si.

Resultado prático: a maior parte das irregularidades só aparece quando um jornalista passa meses cruzando planilhas na mão, ou quando uma investigação policial já está em curso. Não existe hoje uma ferramenta acessível que faça esse cruzamento de forma automática e sistemática.

O Hórus nasce pra resolver isso. O nome vem do deus egípcio do céu e da vigilância — o olho que tudo vê — e resume bem a proposta: um sistema que observa, conecta e revela o que os dados escondem nas entrelinhas.

Em uma frase

O Hórus é uma plataforma web que cruza múltiplas bases de dados públicas brasileiras para identificar automaticamente padrões de irregularidade envolvendo agentes públicos, empresas e contratos governamentais.

2. Problema Abordado

O controle social da gestão pública enfrenta três obstáculos estruturais que o Hórus se propõe a atacar diretamente:

- **Fragmentação:** as informações relevantes estão distribuídas em portais completamente independentes (Transparência Federal, Receita Federal, TSE, TCU, CGU, Diário Oficial) sem qualquer integração entre eles.
- **Volume e complexidade:** cruzar essas bases manualmente pra identificar relações entre agentes públicos, empresas e contratos é inviável sem automação. São gigabytes de dados em formatos diferentes.
- **Opacidade das redes de interesse:** vínculos societários, relações familiares e histórico de doações eleitorais raramente são analisados em conjunto, o que permite que conflitos de interesse passem despercebidos por anos.

2.1 Por que isso importa

Quando uma empresa dona de um contrato público tem como sócio o cunhado de um secretário municipal, isso está nos dados — no CNPJ da Receita Federal e no Portal da Transparência. Mas ninguém cruza isso de forma sistemática. O Hórus faz exatamente esse cruzamento, em escala e de

forma automática.

3. Objetivos

3.1 Objetivo Geral

Desenvolver um sistema web capaz de ingerir, cruzar e analisar dados de bases públicas governamentais, gerando indicadores automáticos de risco de irregularidade envolvendo agentes públicos, empresas e contratos.

3.2 Objetivos Específicos

1. Construir pipelines automatizados de ingestão das principais bases de dados públicas brasileiras.
2. Modelar grafos de relacionamento entre agentes públicos, empresas, sócios e contratos.
3. Aplicar algoritmos de detecção de anomalias para identificar padrões financeiros atípicos.
4. Usar Processamento de Linguagem Natural (NLP) pra extrair entidades do Diário Oficial da União.
5. Entregar dashboards interativos com KPIs de risco, mapas de relacionamentos e relatórios exportáveis.
6. Pontuar cada entidade monitorada com um score de risco calculado a partir de múltiplos cruzamentos simultâneos.

4. Bases de Dados Utilizadas

As fontes de dados foram classificadas em dois tiers de prioridade — o que entra primeiro no sistema e o que vai servir pra enriquecer os dados depois.

4.1 Tier 1 — Núcleo Principal

São as bases com maior potencial de sinal pra detecção de irregularidades e com acesso efetivamente público e gratuito. O cruzamento entre elas já é suficiente pra construir o core do Hórus.

Base de Dados	O que entrega	Acesso
Portal da Transparência (CGU)	Servidores, contratos, convênios, benefícios, vigas oficiais	API REST pública
CNPJ — Receita Federal	Sócios, empresas, situação cadastral, quadro societário completo	Dump ~50 GB (gratuito)
TSE — Dados Eleitorais	Doações de campanha, candidaturas, bens declarados, filiação partidária	Dump CSV por eleição
CEIS / CNEP / CEPIM (CGU)	Empresas e pessoas sancionadas, inidôneas, expulso de contratos públicos	API REST pública
TCU — Contas Públicas	Irregularidades, responsabilizados, acórdãos de condenação	Portal + scraping

4.2 Tier 2 — Enriquecimento

Essas bases entram numa segunda fase e adicionam camadas de contexto ao grafo de relacionamentos.

Base de Dados	O que entrega	Acesso
Diário Oficial da União	Nomeações, exonerações, contratos — extração via NLP	API IN
SIAFI / SIASG	Execução orçamentária, empenhos, pagamentos realizados	Portal
Declarações de Bens (TSE)	Evolução patrimonial de candidatos ao longo dos anos	Dump CSV
Compras.gov (SIASG)	Contratos, licitações, fornecedores e preços praticados	API REST

4.3 Nota Legal — LGPD e CPFs de Agentes Públicos

Respaldo jurídico

O uso de CPFs de agentes públicos no Hórus é legalmente respaldado. A Lei de Acesso à Informação (Lei 12.527/2011) e a jurisprudência do STJ estabelecem que dados de servidores no exercício das funções são de natureza pública. A própria LGPD (art. 4º, III e art. 7º, §3º) prevê exceção expressa para tratamento de dados com finalidade de transparência e controle público. O Portal da Transparência do Governo Federal já disponibiliza CPFs de servidores, validando essa interpretação.

5. Cruzamentos e Detecção de Irregularidades

O diferencial do Hórus é conectar informações de múltiplas fontes num único grafo de relacionamento. Os cinco cruzamentos principais são os que têm maior chance de revelar irregularidades reais:

#	Cruzamento	Irregularidade Detectável	Bases Envolvidas
1	Político → sócio de empresa → contrato público	Conflito de interesse direto	Transparência + CNPJ + SIASG
2	Doador de campanha → ganhou licitação após a eleição	Retorno de favor / captura do Estado	TSE + SIASG
3	Familiar de servidor → empresa contratada pelo mesmo órgão	Nepotismo / testa-de-ferro	CNPJ + Transparência
4	Evolução patrimonial declarada vs salário público recebido	Enriquecimento ilícito	TSE + Transparência
5	Empresa sancionada no CEIS → continua ganhando contratos	Falha de fiscalização / conivência	CEIS + SIASG

Cada um desses cruzamentos já existe nos dados públicos disponíveis. O Hórus automatiza a detecção e apresenta os resultados de forma visual e acessível.

6. Solução Proposta — Arquitetura do Sistema

6.1 Stack Tecnológica

Camada	Tecnologia	Função
API / Backend	FastAPI (Python)	Endpoints REST, orquestração dos pipelines
Processamento	Polars + Pandas	Transformação e cruzamento de grandes volumes
Banco de Dados	PostgreSQL + Apache AGE	Armazenamento relacional com suporte a grafos
Grafos	NetworkX	Modelagem e análise de redes de relacionamento
Filas / Async	Celery + Redis	Ingestão em background sem travar a API
IA / Anomalias	scikit-learn (Isolation Forest)	Deteccção de padrões financeiros atípicos
NLP	spaCy + Gemini API	Extração de entidades do Diário Oficial
Frontend	Next.js 15 + Tailwind CSS	Dashboards, KPIs, painéis interativos
Visualização	Recharts + React Force Graph	Gráficos e visualização interativa do grafo
Infra	Docker + Compose + GitHub Actions	Orquestração local e CI/CD

6.2 Arquitetura em Camadas

O sistema opera em quatro camadas funcionais bem separadas:

Camada de Ingestão

Pipelines automatizados que coletam dados das APIs públicas e dumps governamentais, armazenando-os brutos no PostgreSQL.

Camada de Processamento

Jobs Celery que normalizam, cruzam e constroem o grafo de relacionamentos entre entidades — pessoas, empresas, contratos e órgãos públicos.

Camada Analítica

Modelos de detecção de anomalias e NLP que pontuam cada entidade com um score de risco calculado a partir de múltiplos cruzamentos simultâneos.

Camada de Apresentação

Dashboard Next.js com painéis de KPIs, visualização interativa do grafo de relacionamentos, busca

por CPF/CNPJ e exportação de relatórios.

6.3 Por que PostgreSQL com Apache AGE e não Neo4j?

Neo4j é excelente pra grafos, mas o Community Edition tem limitações sérias de escalabilidade. O Apache AGE é uma extensão do PostgreSQL que adiciona suporte nativo a grafos usando a linguagem Cypher — o melhor dos dois mundos: banco relacional robusto e capacidade de grafo, sem precisar subir um segundo serviço. Pra um projeto acadêmico com restrições de infra, é a escolha certa.

7. Sociedade Impactada

O Hórus tem impacto direto e indireto sobre diferentes grupos:

- **Jornalistas investigativos:** redução drástica do tempo pra investigar conexões entre agentes públicos e contratos, com busca e cruzamento automatizados.
- **Órgãos de controle** (TCU, CGU, MPF, Ministério Público): apoio à identificação de alvos de investigação com base em padrões de dados, complementando o trabalho de auditores.
- **Organizações da sociedade civil** (Transparência Internacional, ARTIGO 19, Contas Abertas): plataforma que democratiza o acesso ao cruzamento de dados públicos sem exigir expertise técnica.
- **Cidadão comum:** ferramenta acessível pra consultar o histórico de contratos e vínculos de qualquer agente público ou empresa fornecedora do governo.

7.1 Métricas de Impacto

- Número de irregularidades identificadas automaticamente pelos cruzamentos.
- Score médio de risco das entidades monitoradas.
- Cobertura percentual dos contratos públicos analisados em relação ao total disponível.
- Tempo médio pra identificação de um padrão de irregularidade (baseline vs. sistema).
- Volume de dados processados por ciclo de atualização.

8. Plano de Trabalho e Cronograma

Etapa	Período	O que será feito	Entregável
Entrega 1			
Relatório de Escopo	23/03 – 27/03/2026	Escopo, justificativa, metodologia e plano de trabalho	Este documento
Desenvolvimento			
Fase A	28/03 – 18/04/2026	Modelagem do banco, pipelines de ingestão (Tier 1), estrutura do GitHub	Repositório + schemas
Fase B	19/04 – 03/05/2026	Cruzamentos principais, grafo de relacionamentos, primeiros KPIs	API funcional
Entrega 2			
Protótipo Funcional	04/05 – 08/05/2026	Demonstração com análise preliminar e telas implementadas	Vídeo demo
Finalização			
Fase C	09/05 – 07/06/2026	IA, NLP no DOU, dashboard completo, score de risco, testes e documentação	Sistema integrado
Entrega 3			
MVP Final	08/06 – 12/06/2026	Demonstração completa, documentação técnica publicada no GitHub	MVP + Vídeo final

9. Considerações Finais

O Hórus é uma aplicação concreta de ciência de dados pra um problema com impacto social real: fortalecer a transparência pública e o controle social no Brasil. Não é um projeto de prateleira — os dados estão disponíveis, as ferramentas existem, e o cruzamento que o sistema faz pode revelar irregularidades que hoje passam despercebidas.

O projeto atende aos requisitos do edital para alunos de TADS — sistema web com painéis, KPIs e indicadores — enquanto aplica técnicas avançadas de ciência de dados: modelagem de grafos, detecção de anomalias e NLP.

A escolha das bases de dados foi guiada pelo critério de máximo sinal com acesso gratuito e público, garantindo viabilidade dentro do semestre. O cronograma distribui o trabalho de forma realista, priorizando as funcionalidades de maior impacto nas fases iniciais.

Derek Cobain — TADS — FAESA — 2026

Referências

- [1] BRASIL. *Lei nº 12.527, de 18 de novembro de 2011* — Lei de Acesso à Informação (LAI). Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2011-2014/2011/lei/112527.htm
- [2] BRASIL. *Lei nº 13.709, de 14 de agosto de 2018* — Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm
- [3] CONTROLADORIA-GERAL DA UNIÃO (CGU). *Portal da Transparência do Governo Federal*. Disponível em: <https://portaldatransparencia.gov.br>
- [4] TRIBUNAL SUPERIOR ELEITORAL (TSE). *Repositório de Dados Eleitorais*. Disponível em: <https://dadosabertos.tse.jus.br>
- [5] RECEITA FEDERAL DO BRASIL. *Dados Públicos CNPJ*. Disponível em: <https://dados.gov.br/dados/conjuntos-dados/cadastro-nacional-da-pessoa-juridica---cnpj>
- [6] APACHE SOFTWARE FOUNDATION. *Apache AGE — Graph Extension for PostgreSQL*. Disponível em: <https://age.apache.org>
- [7] OWASP. *OWASP Top Ten 2021*. Disponível em: <https://owasp.org/www-project-top-ten/>